German Lipnet

Audio-visuelles Lippenlesen auf Deutsch: bestes berichtetes Ergebnis auf GLips-15

Peter Staykov, Dorian Benbassat, Konstantin Borodulin
Bundeswettbewerb Künstliche Intelligenz 2026

1. Datensatz und Vorverarbeitung

GLips (Schwiebert et al., LREC 2022) besteht aus Reden im **Hessischen Landtag**. Jeder Clip zeigt ein Wort aus einer echten Plenarrede: 1,16 s, 29 Frames bei 25 fps, mit Tonspur. Den veröffentlichten Split mit 400/50/50 Clips pro Wort verwenden wir unverändert.
Insgesamt rund 250.000 Clips zu 500 Wörtern aus 1.018 Sitzungsvideos. Für den Vergleich mit Vorarbeiten nutzen wir zusätzlich die 15-Wort-Teilmenge von Ameer et al. (2025).

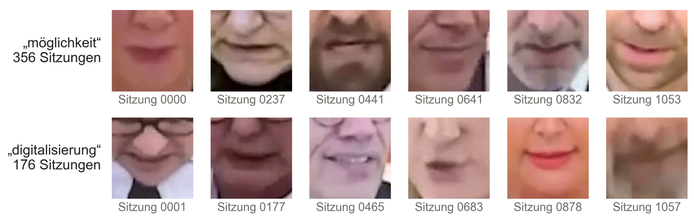
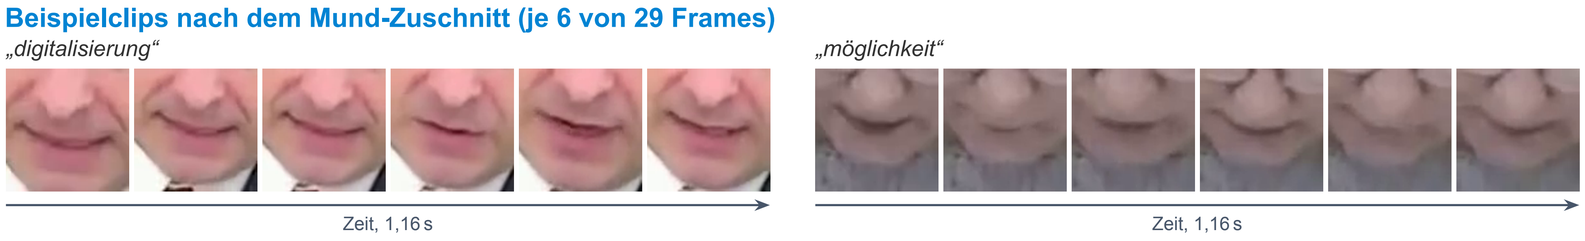


Abbildung 1: Dasselbe Wort aus verschiedenen Sitzungen: Sprecher, Licht und Bildqualität variieren stark.

GLips-15: aber, aufgaben, bleibt, darüber, digitalisierung, einmal, finden, gegen, geworden, herrn, investitionen, kommunen, linke, möglichkeit, passiert

Beispielclips nach dem Mund-Zuschnitt (je 6 von 29 Frames)

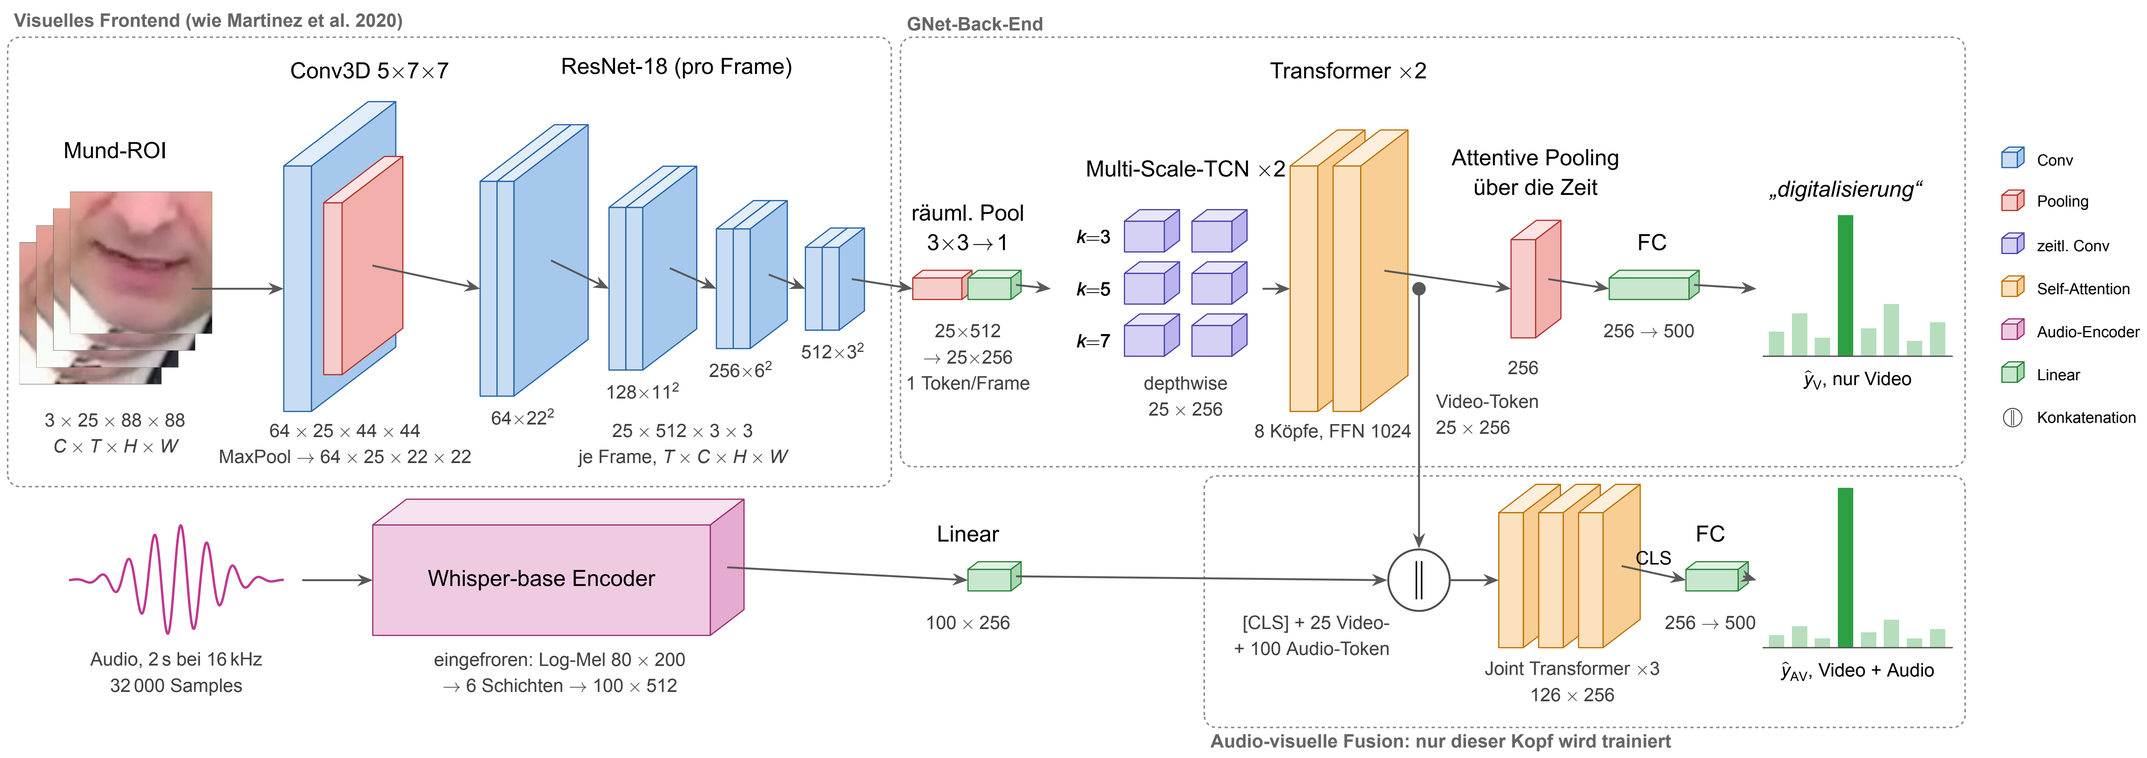


Vorverarbeitung



ganzes Gesicht, 29 Frames, 25 fps → Lippenlandmarken pro Frame, Quadrat mit 1,6× Mundbreite → exponentiell, $\alpha = 0{,}4$: der Ausschnitt springt nicht → skaliert auf 96 × 96 → nur im Training: Ausschnitt 88 × 88, Spiegelung, Helligkeit, Graustufen, Affin, Erasing → 3 × 25 × 88 × 88, 25 gleichverteilte Frames

2. Modell



3. Ergebnisse

Trainingskurven (Validierung)

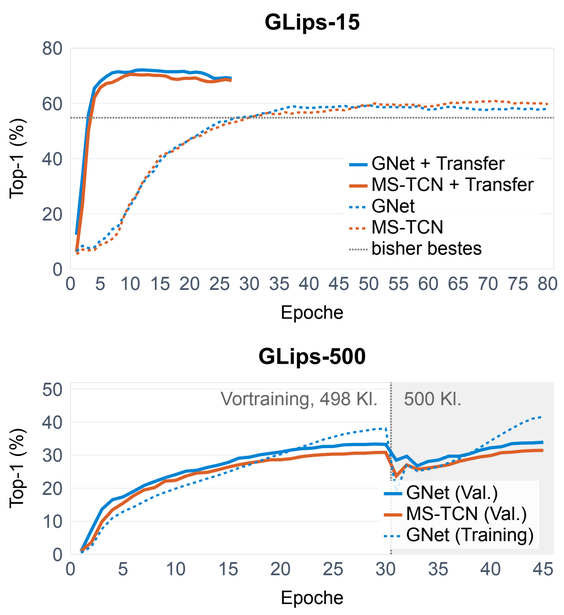


Abbildung 2: Mit Transfer vom 500-Wort-Modell übertrifft GNet nach 5 Epochen das Training von Grund auf nach 80.

Vergleich mit Vorarbeiten (GLips-15)

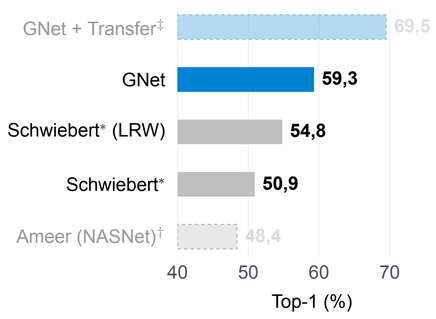


Abbildung 3: Grau: veröffentlichte Ergebnisse, blau: unsere (Test-Split). * Wortauswahl nicht veröffentlicht, nur näherungsweise vergleichbar. † Ganzes Gesicht ohne Mund-Zuschnitt, daher nur zur Einordnung. ‡ Mit Vortraining auf allen 500 GLips-Wörtern (nur Trainingsclips), Schwiebert: Vortraining auf LRW.

Ablation (GLips-15, ohne Transfer)

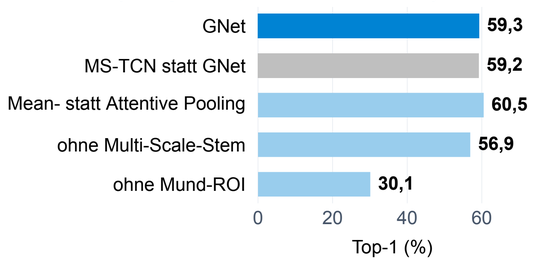


Abbildung 4: Ohne Mund-Zuschnitt halbiert sich die Genauigkeit. Alle anderen Unterschiede liegen innerhalb des 95-%-KI von ±3,5 Punkten.

Ergebnisse auf dem Test-Split

Aufgabe	Modell	Param.	Top-1	Top-5	△
GLips-500	MS-TCN	17,8 M	31,9	51,5	
	GNet	13,6 M	**34,2**	**53,9**	+2,3
GLips-15	MS-TCN	17,6 M	59,2	**86,7**	
	GNet	13,4 M	**59,3**	85,7	+0,1
+ Transfer	MS-TCN	17,6 M	68,5	**89,5**	
	GNet	13,4 M	**69,5**	88,9	+1,0

Tabelle 1: Angaben in %, Bestwert je Aufgabe blau. △: Top-1 GNet minus MS-TCN.

Audio-visuelle Fusion (GLips-500)

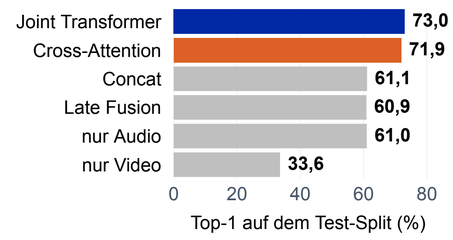


Abbildung 5: Einfache Fusion bringt kaum mehr als reines Audio. Erst Attention zwischen Video- und Audio-Token hebt die Genauigkeit um 12 Punkte. Nur Video: auf den zwischengespeicherten Tokens der Fusion (direkt ausgewertet 34,2, Tab. 1).

Robustheit bei gestörtem Ton (GLips-500, Test)

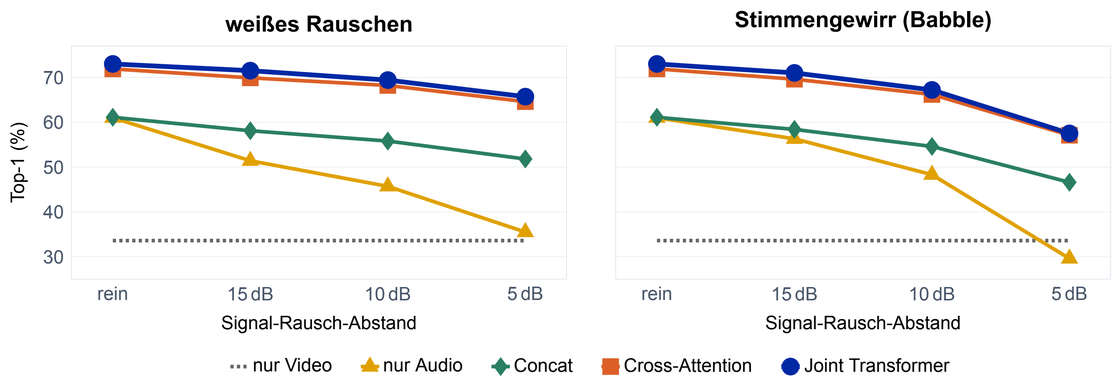
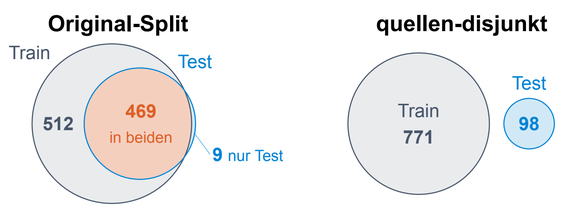


Abbildung 6: Additives Rauschen im Audiosignal. Bei 5 dB Babble fällt reines Audio unter das Nur-Video-Niveau, die Fusion bleibt mit 57,5 % deutlich darüber.

4. Diskussion

Generalisierung auf ungesehene Daten

Im Original-Split stammen fast alle Testclips aus Aufnahmen, die auch im Training vorkommen.



Überlappung: 741/750 Clips
Top-1: **59,3 ± 3,5 %**

Überlappung: 0/766 Clips
Top-1: **58,4 ± 3,5 %**

Abbildung 7: Aufnahmen in Train und Test (GLips-15), Fläche ∝ Anzahl; ±: 95-%-KI.

Wo GNet sich irrt (GLips-15, Transfer)

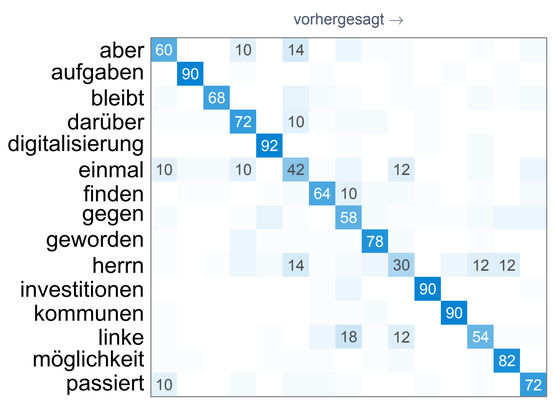


Abbildung 8: Konfusionsmatrix in %. Kurze Wörter (*herrn* 30 %) sind visuell verwechselbar, Genauigkeit und Wortlänge: $r = 0{,}74$.

Einschränkungen

- Alle Aufnahmen stammen aus einem Landtag
- Das Vokabular ist auf 500 Einzelwörter begrenzt
- Kurze Wörter wie „herrn“ und „einmal“ sind visuell leicht verwechselbar
- Sprecher überschneiden sich zwischen Train und Test (GLips enthält keine Sprecher-Labels)

Ausblick

- Mehr Sprecher und Alltagsaufnahmen
- Verschiedene visuelle Frontends testen
- Mehr Daten, damit der Transformer seinen Vorteil ausspielen kann
- Ein echtes Produkt, z. B. für stumme Menschen

Fazit

- Bestes berichtetes Ergebnis auf GLips-15 (Vergleichbarkeit eingeschränkt, s. Fußnoten)
- Unseres Wissens erstes Ergebnis auf dem vollen 500-Wort-Vokabular
- **Vorverarbeitung schlägt Back-End:** Mund-Zuschnitt (+29,2) und Transfer (+10,2) wirken stärker als die Wahl des zeitlichen Modells
- Auf GLips-15 liegt GNet gleichauf mit MS-TCN, auf GLips-500 +2,3 **Punkte** mit 4 M weniger Parametern
- Unseres Wissens erstes multimodales Ergebnis: **73,0 %** auf 500 Wörtern, robust gegenüber Rauschen

Literatur. Schwiebert et al., LREC 2022 (GLips) • Ameer et al., IEEE Access 13, 2025 (NASNetMobile) • Martinez et al., ICASSP 2020 (MS-TCN) • Radford et al., ICML 2023 (Whisper) • Shi et al., ICLR 2022 (AV-HuBERT) • He et al., CVPR 2016 (ResNet) • Lugaresi et al., arXiv:1906.08172, 2019 (MediaPipe)

Literatur

[1] G. Schwiebert, C. Weber, L. Qu, H. Siqueira, S. Wermter. *A Multimodal German Dataset for Automatic Lip Reading Systems and Transfer Learning.* In: Proceedings of the Thirteenth Language Resources and Evaluation Conference (LREC), Marseille, S. 6829–6836, 2022.

[2] A. W. A. Ameer, P. Salehpour, M. Asadpour. *Deep Transfer Learning for Lip Reading Based on NASNetMobile Pretrained Model in Wild Dataset.* IEEE Access, Bd. 13, S. 11623–11638, 2025. doi:10.1109/ACCESS.2024.3470521.

[3] B. Martinez, P. Ma, S. Petridis, M. Pantic. *Lipreading Using Temporal Convolutional Networks.* In: IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP), S. 6319–6323, 2020.

[4] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, I. Sutskever. *Robust Speech Recognition via Large-Scale Weak Supervision.* In: Proceedings of the 40th International Conference on Machine Learning (ICML), PMLR 202, S. 28492–28518, 2023.

[5] B. Shi, W.-N. Hsu, K. Lakhotia, A. Mohamed. *Learning Audio-Visual Speech Representation by Masked Multimodal Cluster Prediction.* In: International Conference on Learning Representations (ICLR), 2022.

[6] K. He, X. Zhang, S. Ren, J. Sun. *Deep Residual Learning for Image Recognition.* In: IEEE Conference on Computer Vision and Pattern Recognition (CVPR), S. 770–778, 2016.

[7] C. Lugaresi, J. Tang, H. Nash, C. McClanahan, E. Uboweja, M. Hays, F. Zhang, C.-L. Chang, M. G. Yong, J. Lee, W.-T. Chang, W. Hua, M. Georg, M. Grundmann. *MediaPipe: A Framework for Building Perception Pipelines.* arXiv:1906.08172, 2019.