Notizen

1 Datensatz

- Auf Schritt 1 „Rohclip“ zeigen. **Wichtig:** nicht die Lippen, sondern das ganze Gesicht. Schwiebert zeigt mund ROI
- Hessischer Landtag, ca. 250.000 Clips, je 1,16 s, 25 fps, mit Tonspur, offizieller Train-/Val-/Test-Split, 1.018 Aufnahmen.
- 15 Wörter nach Ameer et al. **Schwiebert et al. veröffentlichen ihre Wortauswahl nicht** Teilmengen zufällig? Werte nur näherungsweise vergleichbar -> Gebiet noch nicht groß erforscht.
- alphabetisch ersten 15 Wörter getestet, aber die waren sich zu ähnlich. Ameers Wörter sind zufällig gewählt.
- Unterschiede quality der sessions zeigen dazu kommen wir später

1.1 Vorverarbeitung

- MediaPipe FaceMesh (Google) liefert die Lippen-Landmarks. Quadrat mit Seitenlänge $\max(\text{Breite}, \text{Höhe}) \times 1{,}6$, zentriert auf die Mitte der Bounding-Box der Lippen.
- Glättung mit EMA, $\alpha = 0{,}4$ (der aktuelle Frame zählt 40 %, der Verlauf 60 %):

$$\tilde{x}_t = \tfrac{1}{2}\big(\min_i x_{i,t} + \max_i x_{i,t}\big), \qquad x_t = \alpha\,\tilde{x}_t + (1-\alpha)\,x_{t-1}, \quad \alpha = 0{,}4$$

  $\tilde{x}_t$ = rohe Mitte aus den Landmarks, x_t = geglättete Mitte für den Zuschnitt. Nach ca. 5 Frames (0,2 s) zählt ein Frame weniger als 8 %.
- Falls gefragt, was „Affin“ bei der Augmentierung heißt: Rotation $\pm 10°$, Verschiebung ± 6 %, Skalierung ± 10 %. Einmal pro Clip gezogen und auf alle Frames gleich angewendet, nur im Training.

2 Modell

2.1 Einordnung der Vorarbeiten

- **Martinez et al. (2020)** setzten mit dem MS-TCN den damaligen State of the Art auf LRW (BBC). Unser Frontend folgt ihrem Aufbau.
- **Schwiebert et al. (2022)** stellen GLips vor und zeigen Transfer zwischen LRW und GLips. X3D architektur. Verbesserungsbedarf
- **Ameer et al.** nutzen **NASNetMobile**: ein auf ImageNet vortrainiertes, kleines Bildnetz (4,7 M Parameter), angewendet auf jeden Frame des ganzen Gesichts (128×128, 16 Frames), dahinter ein GRU. Ergebnis: 48,4 %.

Warum wir NASNet nicht auf unsere Mund-Zuschnitte anwenden

Wir vergleichen zeitliche Back-Ends (MS-TCN vs.Transformer)

2.2 Architektur

- **Conv3D** ($5 \times 7 \times 7$) über Zeit, Höhe und Breite, RGB rein, 64 Kanäle raus. Danach MaxPool.
- **ResNet-18**, auf jedem Frame einzeln. Am Ende 512 Kanäle $\times\ 3 \times 3$ Pixel pro Frame. Das kleine 3×3 ist gewollt: Das ResNet verdichtet die Information in die 512 Kanäle, darum geht beim räumlichen Pooling wenig verloren.
- **Räumliches Average-Pooling** $3 \times 3 \to 1$: Mittelwert über die 9 Positionen, keine lernbaren Gewichte.
- **Linear 512** $\to$ **256** + LayerNorm: legt die Arbeitsbreite fest (die Residualverbindungen brauchen gleiche Größe), hält den Transformer klein ($\approx$ 1,6 M statt 6,3 M Parameter) und normalisiert die Merkmale.
- **Multi-Scale-TCN**, Kernel 3, 5, 7 wie bei Martinez. Aber ohne Dilation und depthwise (siehe unten).
- **Transformer**: 8 Köpfe ist der Standardwert. Für eine Hyperparametersuche oder Kreuzvalidierung hatten wir keine Ressourcen. Die Köpfe können z. B. auf Mundöffnung, Vokal oder Nachbar-Frames achten.
- **FFN 1024**: Standard, $4\times$ die Breite 256. Kleines 2-Schicht-Netz pro Token innerhalb jeder Transformer-Schicht.

2.2.1 Multi-Scale-TCN (in GNet)

- Drei Zweige parallel mit Kernel $k = 3, 5, 7$.
- **Depthwise:** Jeder der 256 Kanäle bekommt seinen eigenen Filter mit k Gewichten über die Zeit. Padding $k/2$ (abgerundet), damit die 25 Frames erhalten bleiben.
- **1×1-Convolution:** mischt danach die 256 Kanäle innerhalb eines Frames.
- Die drei Zweige werden **gemittelt** (nicht aneinandergehängt), dann Residual + LayerNorm. Ergebnis bleibt 25×256: ein Token pro Frame.
- Zwei Blöcke hintereinander: Sichtfeld 13 Frames ($\approx$ 0,5 s). Den Rest des Clips verbindet der Transformer.

2.2.2 Audio

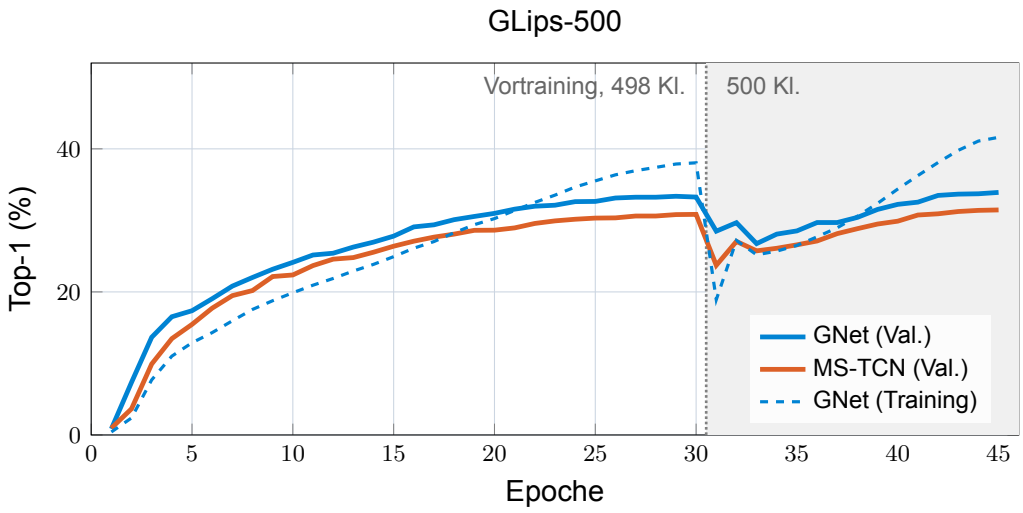
- **Whisper-base-Encoder**, mehrsprachig, eingefroren. Nur der Encoder, also nur Audio-Merkmale, kein Sprachmodell.
- 1,16 s Ton, mit Stille auf 2 s aufgefüllt $\rightarrow$ 100 Tokens à 512.
- Whisper fügt vor seinen 6 Blöcken eigene sinusförmige Positions-Embeddings hinzu. Die Position steckt also schon im Inhalt der Tokens (als Information, keine magischen Zahlen). Für die Fusion: Linear auf 256 + Typ-Embedding (Video/Audio).
- **Nur Audio:** Mittelwert über die 100 Tokens $\rightarrow 1 \times 512$, LayerNorm, Linear 512 $\rightarrow$ 1024, GELU, Dropout 0,3, Linear 1024 $\rightarrow$ 500. **Whisper hat in seinen Embeddings schon globalen zeitlichen Kontext** (Self-Attention über alle Tokens), deshalb braucht es kein GNet-Back-End.

2.2.3 Fusion

- Joint Transformer mit 3 Schichten: ein bewusst kleiner Fusionskopf auf bereits tiefen Merkmalen.

3 Ergebnisse

- Gesunde Trainingskurven. Auf 500 Wörtern beginnt Overfitting (Training steigt weiter, Validierung flacht ab), deshalb Abbruch nach 15 Epochen.
- MS-TCN auf 500 Wörtern: ca 30% leicht unter GNet. Lässt sich vermuten, dass auf mehr vokabular und mehr Daten GNet besser wird, da Transformer besser auf vielen Daten sind.
- Technische schwierigkeiten deswegen bei 30 prozent anfang. Voller plot:



- **Transfer:** Alle Gewichte des 500-Wörter-Modells außer dem Klassifikator dienen als Initialisierung, dann wird alles weitertrainiert. Das 500er-Modell hat nur Trainingsclips gesehen.
- **Ausgegraut** im Vergleich mit Vorarbeiten:

- GNet + Transfer, weil es mit Vortraining auf allen 500 Wörtern nicht direkt mit den Vorarbeiten vergleichbar ist.
- Ameer (NASNet), weil es auf dem ganzen Gesicht ohne Mund-Zuschnitt arbeitet. Wir richten uns nach der etablierten Lipreading-Architektur;

3.1 Ablationen

- **Transformer vs. MS-TCN:** kein messbarer Vorteil. Beide sehen den ganzen Clip, und der ganze zeitliche Kontext reicht. Deshalb vermutlich auch nur ein kleiner Vorteil für DC-TCN (nur mit Ensemble). Auf mehr Vokabular und mehr Daten lässt sich ein Vorteil von GNet erahnen.
- **Mean-Pooling reicht**
- **Ohne Multi-Scale-Stem:** etwas schlechter (56,9 statt 59,3), selbsterklärend.
- **Ohne Mund-ROI:** -29 Punkte, die Lippen sind das Wichtigste.

4 Diskussion

- Alle Aufnahmen stammen aus einem Landtag: frontal, gut ausgeleuchtet, erwachsene Sprecher.
- Ähnliche Wörter wie „herrn“, „einmal“ und „linke“ untrennbar.
- Sprecher überschneiden sich zwischen Train und Test (keine Sprecher-Labels in GLips).
- Auf 15 Wörter merk sich das Modell die Länge nicht das Wort
- Das Vokabular ist auf 500 Einzelwörter begrenzt, ganze Sätze werden nicht erkannt.

4.1 Zukünftige Arbeit

- Frontends Vergleichen
- Sentence Level
- Super resolution
- Mehr Daten
- speaker disjoint