Notizen

1 Datensatz und Vorverarbeitung

- GLips: Hessischer Landtag, ca. 250.000 Clips, 500 Wörter, 1,16 s, 25 fps, mit Ton. Offizieller Split unverändert.
- **Datensatz = ganzes Gesicht**, den Mund schneiden wir selbst aus (Ablation: -29).
- GLips-15 = Ameers Wörter (zufällig). Schwieberts Auswahl unveröffentlicht $\rightarrow$ Sternchen.
- FaceMesh $\rightarrow$ Quadrat $1{,}6\times$ Mundbreite. EMA $\alpha = 0{,}4$: Frame-Gewicht 40, 24, 14, 9, 5 % $\rightarrow$ nach 4 Frames nur noch ca. 5 %.
- Affin: Rotation $\pm 10°$, Verschiebung ± 6 %, Skalierung ± 10 %, pro Clip gleich, nur Training.

2 Modell

- **Conv3D** $5\times7\times7$, RGB $\rightarrow$ 64 Kanäle, zufällig initialisiert.
- **ResNet-18** pro Frame: nur layer1–4 mit ImageNet-Gewichten (conv1/MaxPool ersetzt durch Conv3D). **Abweichung von Martinez** (dort von Grund auf).
- 3×3-Pooling $\rightarrow$ Linear 512$\rightarrow$256: Transformer 1,6 M statt 6,3 M Parameter.
- **Multi-Scale-TCN**: $k = 3, 5, 7$, depthwise, ohne Dilation, Zweige gemittelt. 2 Blöcke $\rightarrow$ Sichtfeld 13 Frames.
- **Transformer** $\times2$: 8 Köpfe, FFN 1024 (Standardwerte, keine HP-Suche).
- **Attentive Pooling** bleibt im Modell: Mean war 60,5 vs. 59,3 (im Rauschen), Transformer hat schon Attention. Hauptläufe waren schon trainiert. **Ehrlich sagen, nicht verteidigen.**

2.1 NASNet (Ameer, 48,4 %)

- ImageNet-Bildnetz pro Frame, ganzes Gesicht, GRU dahinter.
- Unser Fokus: Back-Ends bei festem Frontend $\rightarrow$ NASNet ist eine andere Frage.
- GNet/MS-TCN auf Ameers Input (ganzes Gesicht): nur 18,9 / 22,5 % (Val.). **Ehrlich:** NASNet dort klar besser. Unser Vorsprung kommt vom Mund-Zuschnitt.
- NASNet auf Mund-Zuschnitten könnte besser sein $\rightarrow$ **nächstes Experiment**.
- Nicht sagen: „technisch nicht möglich“, „kompliziert“, „nicht für Lippenlesen gemacht“.

2.2 Audio (Whisper-base, eingefroren)

- Encoder: Log-Mel 80 $\rightarrow$ 2 Conv (Stride 2) $\rightarrow$ 6 Transformer-Blöcke (8 Köpfe, 512). 680.000 h Training.
- 1,16 s auf 2 s aufgefüllt $\rightarrow$ 100 Tokens à 512 (ca. 42 davon Stille).

- Nur Audio = Probe: Mittelwert $\rightarrow$ MLP 512$\rightarrow$1024$\rightarrow$500. Whisper hat schon zeitlichen Kontext.
- **Nicht sagen** „Attention auf Attention bringt nichts“: Unser bestes Modell ist genau das. Transformer-Kopf nur auf Audio = stärkere Baseline, nicht trainiert.
- 61 %: Aufgabe schwer (Whisper-ASR nur 10,7 %). Zeigt nicht, dass unser Kopf stark ist.
- **Warum 2 s** (falls gefragt):
  - Whisper verarbeitet immer 30-s-Fenster und füllt kürzeres Audio mit Stille auf. Stille am Ende ist für Whisper also der Normalfall, nicht ungewohnt.
  - Bei unseren 1,16-s-Clips wären 30 s zu 96 % Stille. Wir schneiden die Stille einfach früher ab: 2 s $\rightarrow$ 100 statt 1500 Tokens, 15$\times$ weniger Rechenzeit.
  - Die ersten 100 Positions-Embeddings sind genau die, mit denen Whisper trainiert wurde, es ändert sich nichts an der Architektur.
  - Puffer statt exakt 1,16 s: Clips variieren leicht in der Länge, nichts wird abgeschnitten.
  - Die Stille-Tokens sind nicht leer: Über 6 Schichten Self-Attention tragen sie Information aus dem gesprochenen Teil.

2.3 Fusion

- Late/Concat $\approx$ Audio: gemittelte Vektoren, Audio dominiert.
- Nicht nur Kapazität: Cross-Attention 0,52 M (71,9) $>$ Concat 0,98 M (61,1).
- **Hauptaussage:** Der Beitrag des Videos zeigt sich unter Rauschen.
- Ton aus: Fusion 30,7–32,0 % $\approx$ Video-Niveau.
- Kein Rausch-Augment, **aber Modality Dropout** (20 % ohne Ton) $\rightarrow$ lernt Rückfall aufs Video.
- 5 dB Babble: 57,5 vs. 29,6 % Audio. 0 / -5 dB nicht getestet.
- AV-HuBERT: gleiches Prinzip, aber Englisch/Sätze $\rightarrow$ kein direkter Vergleich.

3 Ergebnisse

- Vorarbeiten: Schwiebert (Datensatz-Paper, X3D, Transfer von LRW) und Ameer (NASNet).
- **Formulierung:** „bestes berichtetes Ergebnis auf GLips-15“, nicht SOTA. Auch ohne Transfer (59,3) vor allen veröffentlichten Werten.
- **Transfer** ist ein Benchmark, keine Praxis-Anwendung: Er zeigt, wie weit man theoretisch kommt (500er-Modell, nur Trainingsclips, als Start). Ausblick (JuFo): die theoretische Obergrenze für deutsches Lippenlesen.
- GLips-500: GNet 34,2 vs. MS-TCN 31,9 (**+2,3**, KI $\pm 0{,}6$), beide 15 Epochen.
- GLips-15: +0,1 $\rightarrow$ im Rauschen ($\pm 3{,}5$). Kernaussage: Vorverarbeitung $>$ Back-End.
- Generalisierungslücke wächst, Val. steigt noch $\rightarrow$ kein Overfitting, evtl. untertrainiert.
- Ablationen auf GLips-15: nur Mund-ROI außerhalb des Rauschens. Stem ($-2{,}4$) = Trend.
- Ein Seed pro Lauf. KIs nur über die Testmenge.

- Nur Video: 34,2 (Tab. 1, direkt ausgewertet) vs. 33,6 in der Fusions-Pipeline (gespeicherte Video-Tokens, auf denen die Fusion trainiert wurde).

3.1 Fehleranalyse

- Genauigkeit vs. Wortlänge: $r = 0{,}74$ (Buchstaben und Phoneme). ≤ 5 Phoneme: 52 %, ≥ 7: 87 %.
- Grund 1: mehr verschiedene Viseme. Grund 2: fester 1,16-s-Clip $\rightarrow$ bei kurzen Wörtern mehr Nachbarwörter im Bild.
- Begriff: „visuell verwechselbar“ / Homoviseme, nicht Homophene.

4 Ethik

- Dual Use (Überwachung) $\rightarrow$ **Einwilligung, lokal auf dem Gerät, keine Speicherung.**
- „Modell zu schwach“ nur als Nebensatz, Methoden skalieren.
- Nächster realistischer Schritt: Sätze statt Einzelwörter, mehr Sprecher.